Разработка приложения для обнаружения фишинговых и мошеннических сообщений

FraudShield
Development of an Application for Detecting Phishing and Fraudulent Messages

Материалы к первому апробационному периоду
Software Engineering · SE-2428
20 октября 2026 года

Команда
Кендебаев Нұрасыл Ауесбекұлы
Амирханов Асхат Нурланулы

Руководитель
Серек Азамат Галымжанович
Ассоциированный профессор

Проект предусматривает ручную проверку подозрительного текста и ссылок с объяснением признаков риска. На данном этапе представлены анализ предметной области, проектные требования, архитектура, макеты и план оценки.

Статус: рабочая версия для проверки командой и руководителем. Пользовательские интервью, подтверждённые результаты испытаний, замечания руководителя и ссылки на командные системы добавляются после получения фактических материалов. Раздел 11 содержит перечень недостающих подтверждений.

1 Предложение проекта

Проблема и аудитория

Пользователь получает сообщение от имени банка, службы доставки или государственного сервиса и должен решить, можно ли доверять просьбе, ссылке или требованию срочного действия. Предлагаемая система помогает оценить такое сообщение до перехода по ссылке. Основная аудитория - пользователи мобильных устройств в Казахстане, читающие сообщения на русском или казахском языке.

Цель

Разработать и оценить прототип приложения, который принимает текст сообщения, выявляет признаки фишинга и мошенничества, проверяет структуру содержащихся ссылок и выдаёт понятное объяснение риска на выбранном языке интерфейса.

Задачи

1. Изучить подходы к smishing и ограничения доступных датасетов.
2. Проверить потребности пользователей и согласовать измеримые требования.
3. Подготовить обезличенный корпус и правила разметки.
4. Реализовать клиент, API, хранение истории по согласию и модуль анализа.
5. Сравнить правила, простой текстовый классификатор и расширенный подход.
6. Оценить точность, долю ложных тревог, задержку и понятность результата.

Границы

В MVP входят ручная вставка текста, извлечение URL без перехода по ним, объяснение результата и добровольная история проверок. Канал доступа - мобильное веб-приложение; Telegram Mini App рассматривается как оболочка. Автоматическое чтение SMS и личных чатов, проверка звонков, OCR, блокировка платежей и гарантия безопасности сообщения в MVP не входят.

Инженерная сложность и ожидаемый результат

Основные сложности - совместная обработка текста и URL, два языка и смешанные сообщения, согласованные контракты нескольких компонентов, защита приватности и воспроизводимая оценка на данных без утечки между выборками. Результат - интегрированный прототип, репозиторий, документация и отчёт с измеренными показателями. Превосходство над существующими продуктами не заявляется до испытаний.

2 Актуальность и проверка потребностей

Государственные материалы Казахстана описывают фишинг, поддельные сайты и мошенничество в мессенджерах как актуальные схемы [10]. Это подтверждает существование проблемы, но само по себе не доказывает спрос на конкретное приложение. Научные работы показывают значимость локального языка, контекста и данных [1, 2, 7].

ID	Положение	Основание и статус
E1	Фишинг и сообщения от имени сервисов - актуальная проблема	Подтверждено официальным источником [10].
E2	Локальные данные важны для оценки	Следует из исследований [1, 2, 7]; применимость к нашему корпусу проверяется.
H1	Пользователь готов вставлять сообщения вручную	Гипотеза. Проверить в интервью и задании на макете.
H2	Объяснение полезнее одного цветного индикатора	Гипотеза. Проверить понимание результата.
H3	Telegram удобнее отдельного приложения	Гипотеза. Проверить предпочитаемый канал.
H4	История проверок нужна большинству	Гипотеза. Уточнить пользу и готовность сохранять текст.

План обсуждений с пользователями

До фиксации требований провести 3-5 бесед с представителями аудитории: студент, работающий пользователь банковских приложений, взрослый пользователь с небольшим цифровым опытом; при возможности - специалист поддержки. Участие добровольное. Не собирать пароли, коды подтверждения, реквизиты и необезличенную переписку.

Вопросы: какой подозрительный случай был последним; как проверяли; что было неудобно; что готовы передавать сервису; какой язык и канал предпочитают; что означает для них результат «признаки риска не обнаружены»; какие действия выполнят после предупреждения. Завершить заданием на макете без подсказки.

Для каждой беседы зафиксировать дату, обезличенный код участника, категорию аудитории, согласие, фактический ответ, вывод и связанное требование. Протокол хранится в evidence/. Изменения требований фиксируются отдельным решением. Фактических записей бесед в переданных материалах нет; этот пункт пока не закрыт.

3 Обзор научных источников

В обзор включены восемь научных работ [1-8], преимущественно 2024-2026 годов; XLM-R [8] сохранён как фундаментальная работа. Проверены полные тексты: постановка задачи, данные, методы оценки и ограничения. Статус научного постера и препринта указан отдельно. Эксперименты авторов в рамках данного этапа не воспроизводились; выводы для FraudShield являются проектными решениями, а не измеренными результатами.

Источник	Подход и полезный результат	Ограничение и решение для проекта
[1] Cejas et al., 2026	Многоязычные эмбеддинги для HAM, SPAM и SMISHING; локальный запуск с оценкой задержки и памяти.	Закрытый корпус; авторы не приводят метрики по отдельным языкам и не оценивают concept drift. Нужны языковые и временные срезы.
[2] Ali et al., 2025	Краудсорсинг локальных сообщений; LLM в zero/few-shot режимах, F1 по классам и macro-F1.	Мозамбик и португальский; статический временной срез. Перенять протокол локального сбора, не переносить показатели на Казахстан.
[3] Timko, Rahman, 2024	SmishTank: пользовательские smishing-примеры, бренды, домены и репутация в момент сбора.	Состав зависит от версии; фишинговый корпус не заменяет законные сообщения. Фиксировать снимок, дату и происхождение метки.
[4] Nahapetyan et al., 2024	Исследование тактик и инфраструктуры; авторы публикуют сообщения и группировку кампаний.	Схожие кампании могут попасть в разные выборки. Разделять группы шаблонов и доменов при оценке.

Вывод: корпус должен отражать не только ключевые слова, но и источник, язык, дату, кампанию и способ получения метки. Публикации про иностранные сообщения дают методическую основу, но не подтверждают качество на русских и казахских сообщениях.

3 Обзор научных источников продолжение

Источник	Подход и полезный результат	Ограничение и решение для проекта
[5] Hosseinpour, Das, 2025	Четыре потока признаков: региональные сущности, структура, CharCNN и контекст; сравнение с отдельными потоками.	Короткий постер; часть spam размечена как smishing по словам, возможна зависимость от правил меток. Нужны независимая разметка и абляция.
[6] Islam et al., 2024	21 извлекаемый признак URL и CNN; объяснение вклада признаков.	URL-классификация не покрывает сообщения без ссылок. Высокая accuracy на авторском split не доказывает перенос на новые кампании.
[7] Togmanov et al., 2025	KazMMLU оценивает казахский, русский и региональные знания; показывает ограничения моделей.	Задания на знания не являются детекцией фишинга. Использовать как аргумент для языковой оценки, а не как обучающий корпус мошенничества.
[8] Conneau et al., 2020	XLM-R: многоязычное предобучение, перенос и компромисс между числом языков и ёмкостью модели.	Общие NLP-бенчмарки не гарантируют детекцию мошенничества. Измерять качество и ресурсы против TF-IDF на одном split.

Синтез и исследовательский вопрос

Вопрос проекта: даёт ли совместный анализ текста и структуры URL практически полезное качество обнаружения мошенничества на локальном RU/KZ-корпусе при приемлемой доле ложных тревог и времени ответа? Сравнение проводится с правилами и простым текстовым классификатором; отсутствие улучшения также является допустимым исследовательским результатом.

Планируемая практическая особенность - локальные примеры, два языка и понятное объяснение признаков. Заявлять научную уникальность лишь на основании этих признаков нельзя: многоязычные и локально адаптированные подходы уже существуют [1, 2, 5].

Дополнительные источники

UCI SMS Spam Collection [9] пригоден для воспроизводимого базового эксперимента, но spam/ham не тождественны fraud/legitimate. Документация продуктов [11-14] используется для сравнения аналогов, документация технологий [15-20] - для архитектурных решений. Полные ссылки приведены в конце отчёта.

4 Сравнение существующих систем

Сравниваются четыре системы по восьми одинаковым критериям. Сведения взяты из официальных описаний [11-14], дата проверки - 20.10.2026. «Не подтверждено» означает отсутствие доказательства в изученном источнике, а не отсутствие функции. Практическая проверка продуктов на локальном корпусе пока не проведена.

Критерий	Scamio [11]	Norton Genie [12]	VirusTotal [13]	Safe Browsing [14]
Полный текст сообщения	Да	Да	Не основной объект сервиса	Нет, сервис про URL
URL	Да	Да	Да	Да
Изображение / скриншот	Да	Да	Не подтверждено для объяснения сообщений	Не относится к текстовой задаче
Объяснение пользователю	Заявлен анализ и рекомендации	Да, объясняет признаки	Отчёты движков и репутации	Статус опасности URL
RU/KZ качество на локальных схемах	Не подтверждено	Не подтверждено	Не подтверждено	Не оценивает смысл текста
API для нашего приложения	Не подтверждено	Не подтверждено	Есть API; условия проверить	Есть API; ограничения использования
Локальный запуск обработки	Не подтверждено	Не подтверждено	Облачный сервис	Облачная проверка
Роль в сравнении	Прямой функциональный аналог	Прямой функциональный аналог	Аналог URL-компонента	Аналог URL-компонента

Зачем разрабатывать своё решение

Scamio и Genie уже решают похожую пользовательскую задачу. Основание для диплома - разработка и измеримая оценка собственной системы с контролируемым корпусом, RU/KZ-сценариями, политикой хранения и воспроизводимым базовым сравнением. Преимущество в точности, языке или приватности нужно доказать; оно не предполагается автоматически.

Для внешних URL-сервисов перед внедрением проверить тарифы, условия использования, передачу данных и ограничения API. В MVP допустима локальная проверка структуры URL без отправки исходного текста третьим сторонам. Отсутствие URL в репутационной базе не означает безопасность.

5 Выбор технологий

Ниже приведены предварительные решения для обсуждения с командой. Финальный стек фиксируется после проверки компетенций и короткого технического прототипа. Разделение обязанностей соответствует представленным обоснованиям проекта.

Решение	Альтернативы	Предлагаемый выбор и основание
Серверный API	Node.js + Express; Python + FastAPI; ASP.NET Core	Express для пользовательского API и FastAPI для анализа: соответствует ролям и Python-экосистеме. Цена - два сервиса. Если сопровождение сложно, объединить API в FastAPI [15,16,20].
Хранилище	PostgreSQL; SQLite; MongoDB	PostgreSQL: связи пользователей, проверок, версий и отзывов; JSONB для объяснений [17]. SQLite проще локально, MongoDB удобна для документов, но не даёт преимущества для принятой модели связей.
Клиентский канал	Мобильный web / React; Telegram Mini App; нативное приложение	Адаптивный web как основной клиент; Telegram Mini App как оболочка [18]. Не требуется установка приложения; Telegram-вход и ограничения платформы должны проверяться отдельно.
Анализ текста	Правила; TF-IDF + логистическая регрессия; многоязычный encoder	Правила как B0, TF-IDF как B1 [19], encoder как кандидат B2 [1,8]. Выбор B2 только по измерениям. Внешняя LLM - отдельный эксперимент с согласием и проверкой стоимости.
Связь компонентов	REST/JSON; gRPC; очередь задач	REST/JSON: простая отладка и проверка контрактов, достаточно для ручных запросов MVP. gRPC полезен при более жёстких требованиях, очередь - для долгих асинхронных задач.

Критерии пересмотра

Оценивать трудоёмкость интеграции, воспроизводимость сборки, задержку, стоимость и возможность не передавать личный текст внешним сервисам. Если два серверных стека не дают пользы, упростить архитектуру до одного API. Next.js не обязателен: для формы проверки SEO и серверный рендеринг не являются главными требованиями.

6 Функциональные требования

Приоритеты: Must - обязательное для MVP; Should - следующий приоритет. Требования предварительные до пользовательских бесед и согласования руководителем. Критерии приёмки описывают будущую проверку, а не уже пройденные испытания.

ID	Приоритет	Требование	Критерий приёмки
FR1	Must	Вставка текста RU/KZ, 1-5000 символов	Пустой ввод и превышение лимита отклоняются; валидные Unicode-строки принимаются.
FR2	Must	Извлечение и разбор ссылок	Все URL контрольного набора извлекаются; автоматического открытия и загрузки сайтов нет.
FR3	Must	Результат анализа	Возвращаются risk_level, reasons, model_version и status. При сбое status=unavailable, без зелёного результата.
FR4	Must	Понятное объяснение	Каждый найденный сигнал имеет описание и рекомендацию; отсутствие сигналов не названо гарантией безопасности.
FR5	Must	Выбор RU/KZ интерфейса	Ввод, результат, ошибки и подсказки отображаются на выбранном языке; исходный текст не переводится молча.
FR6	Must	История по явному согласию	По умолчанию текст не сохраняется. При согласии запись доступна только владельцу.
FR7	Must	Удаление сохранённой проверки	Владелец удаляет запись; повторное чтение возвращает 404; чужой доступ запрещён.
FR8	Should	Обратная связь о результате	Отзыв хранится отдельно от экспертной метки и не попадает автоматически в обучение.
FR9	Must	Контроль версий анализа	Для сохранённого результата доступны версия алгоритма, время и версия схемы ответа.
FR10	Should	Telegram-оболочка	При включении Mini App сервер проверяет подпись initData; поддельные и устаревшие данные отклоняются.

6 Нефункциональные требования

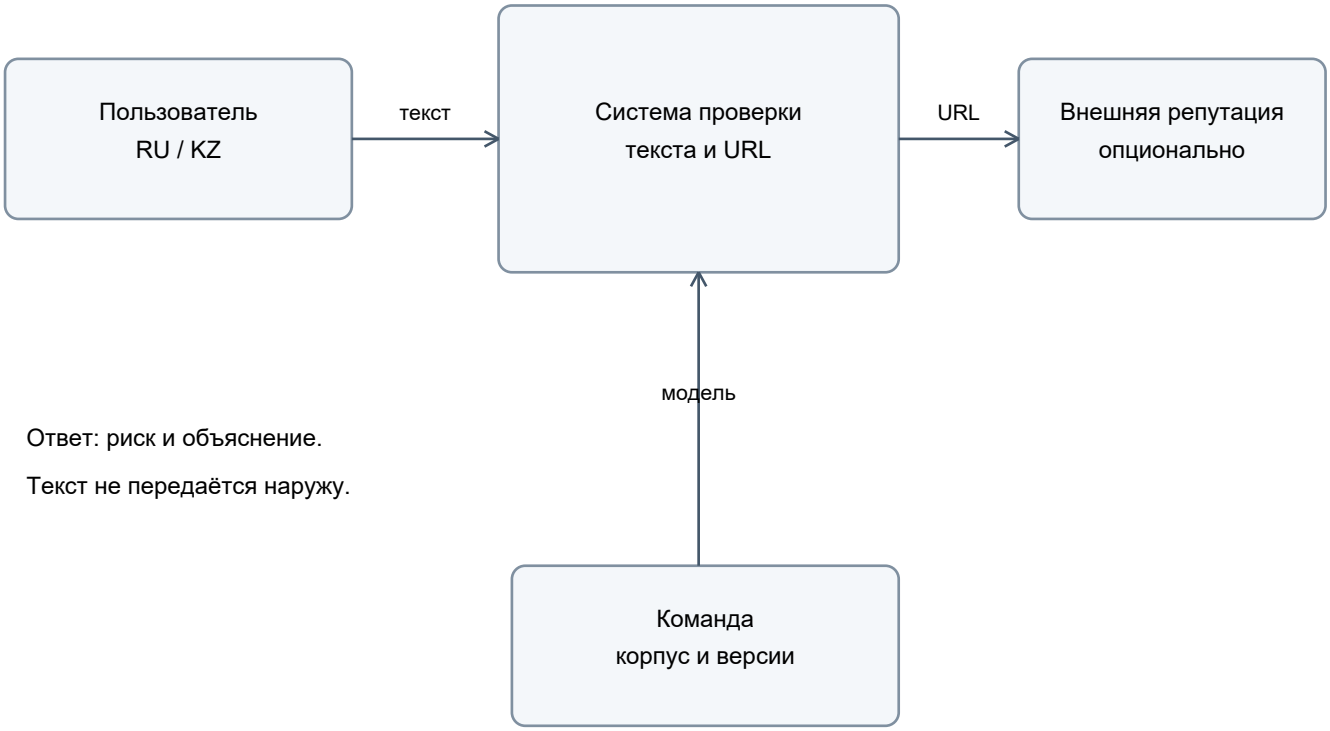
ID	Приоритет	Показатель	Условия и приёмка
NFR1	Must	Локальный анализ p95 ≤ 2 с	1000 запросов после прогрева, 10 одновременных клиентов, вход 100-2000 символов; зафиксировать CPU/RAM и версии. Измерение ещё не выполнено.
NFR2	Must	Тайм-аут ≤ 5 с	При превышении лимита UI показывает недоступность и повтор; результат не подменяется безопасным.
NFR3	Must	Минимизация данных	Не сохранять исходный текст без согласия, исключить его из логов. Проверить журнал и БД на контрольных строках.
NFR4	Must	Изоляция пользователей	Проверки API для чтения/удаления чужой истории отклоняются; секреты хранятся вне репозитория.
NFR5	Must	Воспроизводимость	Чистая установка по lock-файлам и запуск тестов по README; версии модели и split-манифест записаны.
NFR6	Must	Оценка качества по языкам	Отдельные precision, recall, F1 и confusion matrix для RU и KZ; смешанные сообщения выделены отдельно.
NFR7	Should	Понятность интерфейса	4 из 5 участников выполняют проверку без подсказки; фиксировать фактическое число и замечания, не обобщать на население.

Политика результата

Внутренние категории: high, suspicious, low_signal. В интерфейсе: «Высокий риск», «Есть подозрительные признаки», «Явные признаки риска не обнаружены». Сбой обозначается отдельно. Термин «безопасно» из первоначальной идеи заменён на осторожную формулировку, поскольку ошибки классификации неизбежны. Числовая вероятность не выводится, пока калибровка не проверена.

7 Архитектура и сценарии

Контекст системы

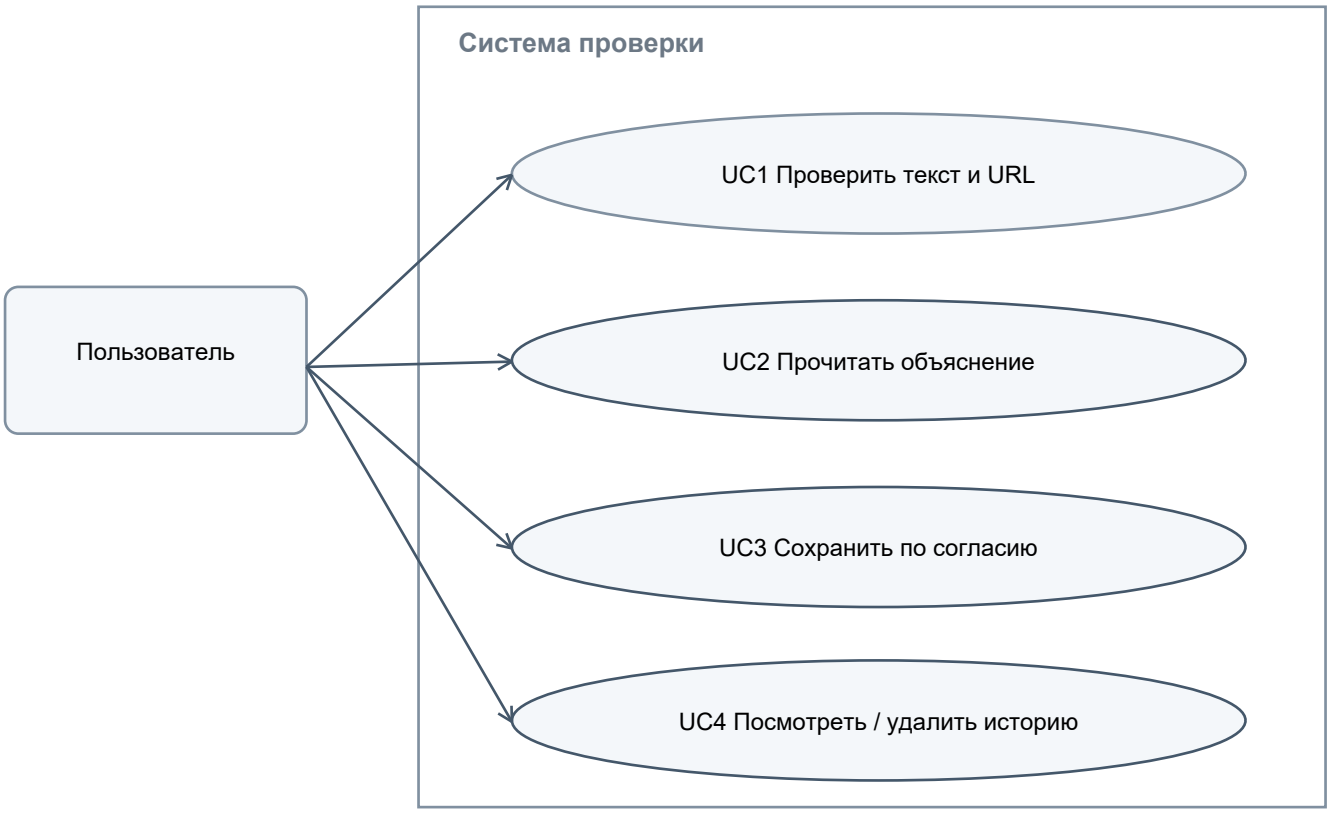


Пользователь вручную передаёт текст и получает оценку. Команда управляет версиями корпуса и модели. Внешняя репутационная проверка URL - расширение; по умолчанию анализ выполняется без перехода по ссылке. Архитектура не требует доступа к чужим чатам или SMS.

Основной сценарий UC1

Пользователь вставляет сообщение → интерфейс проверяет длину → API валидирует запрос → анализатор нормализует текст и извлекает URL → объединяет сигналы → возвращает объяснение → интерфейс показывает результат. Сохранение выполняется только при согласии и наличии аутентифицированного владельца. При тайм-ауте возвращается ошибка доступности.

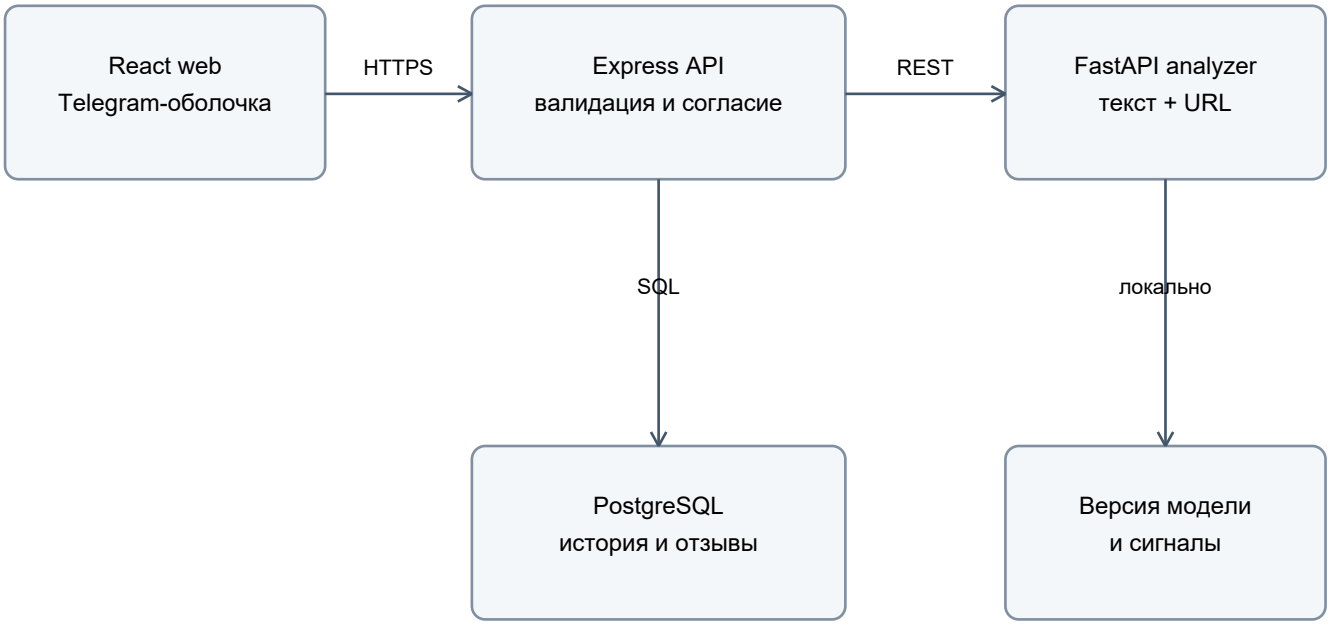
7 Диаграмма вариантов использования



Сценарий	Предусловие	Успех / исключение
UC1 Проверка	Текст допустимой длины	FR1-3. Результат либо явная ошибка без оценки безопасности.
UC2 Объяснение	Проверка завершена	FR4-5. Пользователь видит признаки и следующие действия.
UC3 Сохранение	Вход и явное согласие	FR6, FR9. Запись принадлежит текущему пользователю.
UC4 История и удаление	Пользователь вошёл	FR7. Чужие записи недоступны; удалённая запись не читается.

Обратная связь FR8 является необязательным отдельным действием после результата. Telegram-вход FR10 применяется только при включении оболочки. Общий анонимный сценарий проверки не зависит от Telegram.

7 Компоненты и данные



Проектная схема. Реализация сервисов и интеграция ещё не подтверждены.

Сущность	Назначение и основные поля
User	id, auth_provider, provider_subject; не хранить лишние данные профиля.
Check	id, user_id, created_at, risk_level, reasons_json, model_version, retention_until; текст только по отдельному согласию.
Feedback	id, check_id, user_id, verdict, comment; пользовательское мнение отделено от разметки.
DatasetItem	id, sanitized_text, language, label, source, source_date, consent_or_license, campaign_group, split, annotation_version.

Анонимная проверка не создаёт историю в БД. Нужен явный срок хранения; предварительно 30 дней для добровольной истории с возможностью немедленного удаления. Перед реализацией срок согласовать с командой и руководителем.

8 Контракты и трассируемость

Черновой контракт API

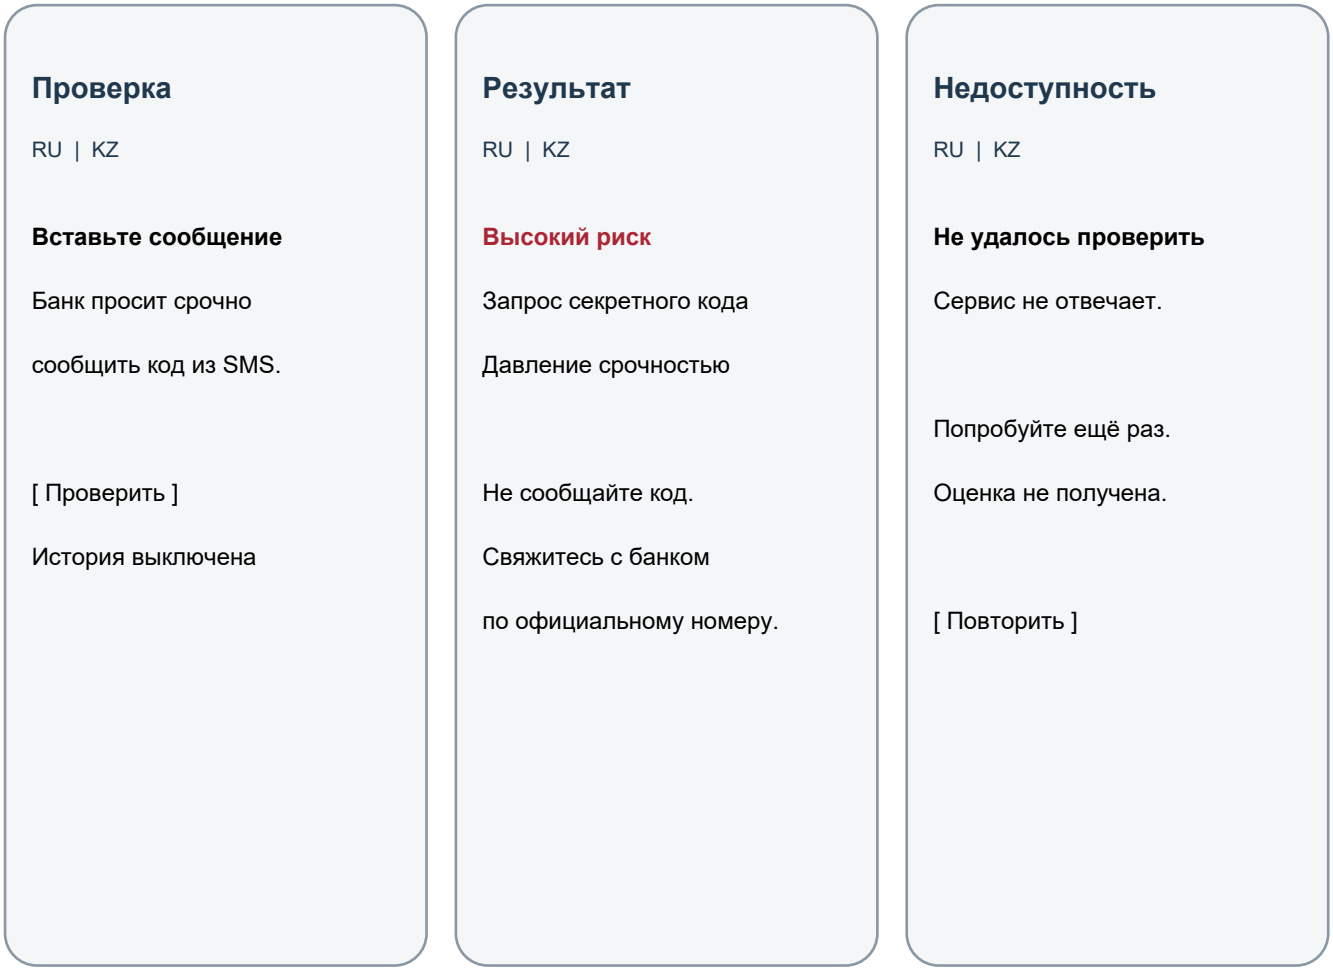
POST /api/v1/checks/analyze
Запрос: text (1-5000 символов), language (ru/kk/auto). Для анонимной проверки текст не сохраняется.
Ответ 200: request_id, status=completed, risk_level, reasons[], urls[], model_version, processing_ms.
Объяснения имеют code и description.
Ответы 422: неверный ввод; 429: превышение частоты; 503: анализ недоступен. Сбой не имеет risk_level=low_signal.

POST /api/v1/history: сохранить результат с явным согласием, только для вошедшего пользователя.
GET /api/v1/history: история текущего владельца.
DELETE /api/v1/history/{id}: удаление своей записи.
POST /api/v1/feedback: необязательный отзыв; не изменяет эталонную метку автоматически.

Связь требований, компонентов и проверок

Требование	Компонент	Проверка
FR1, FR5	Web + API	T1: пустой ввод, границы длины, Unicode, смена языка.
FR2	URL analyzer	T2: URL без схемы, IDN, IP, userinfo, некорректный адрес; без сетевых запросов.
FR3, FR4, FR9	Analyzer + UI	T3: схема ответа, версия, причины, ошибка сервиса.
FR6, FR7, NFR3-4	Auth + API + PostgreSQL	T4: согласие, чужая запись, удаление, отсутствие текста в логах.
NFR1-2	API + Analyzer	T5: нагрузка и тайм-аут на зафиксированной машине.
NFR6	Data pipeline + evaluator	T6: фиксированное разделение, метрики отдельно RU/KZ и по классам.
NFR7	Web prototype	T7: задания с 5 пользователями и протокол ошибок.

9 UX и макеты



Проектные макеты. Демонстрационные тексты не являются пользовательскими данными.

Ключевые взаимодействия

Первый экран объясняет назначение сервиса, лимит ввода и отсутствие автоматического сохранения. Кнопка проверки блокируется при пустом вводе и во время запроса. Результат содержит текстовую категорию, конкретные признаки и понятную рекомендацию; цвет используется только как дополнительный сигнал.

В состоянии «признаки риска не обнаружены» остаётся пояснение: «Это не гарантирует безопасность. Проверьте отправителя через официальный канал». Экран ошибки не использует зелёную отметку. Сохранение и удаление истории показываются только после входа; согласие на историю не заменяет согласие на использование сообщения в исследовании.

Макеты иллюстрируют UC1-2 и состояние сбоя. Экраны истории, KZ-локализация и Telegram-вход должны пройти отдельную проверку. Редактируемая спецификация макетов находится в prototype/wireframes.md. Реальные пользовательские тесты пока не проведены.

10 Проверка качества и данные

Сбор и разметка

Предлагаемый пилот: 600 обезличенных сообщений, по 300 для RU и KZ; дополнительно учитывать смешанный язык. Целевой минимум для каждого языка - 100 мошеннических и 100 законных сообщений. Это план сбора, а не объём уже имеющихся данных. При недостатке данных сократить выводы и явно указать размер, не заменять реальные проверки синтетическими.

Источники: добровольные обезличенные примеры с согласованным использованием; открытые корпуса с проверенными условиями; опубликованные предупреждения с проверенной допустимостью переработки. Записывать происхождение и основания метки. Удалять телефоны, имена, коды, реквизиты и URL-токены; исходный секретный текст не коммитить.

Две основные эталонные метки: fraud и legitimate; uncertain направляется на разбор. Оба участника независимо размечают пилотные 100 примеров, фиксируют расхождения и правила разрешения. «Подозрительно» в интерфейсе - зона неопределённости решения, а не автоматически отдельный истинный класс. Рекламный spam отдельно помечается и не считается мошенничеством без основания.

Разделение и базовые варианты

После дедупликации сформировать train/validation/test ориентировочно 60/20/20 по группам кампаний и шаблонов, с сохранением языковых долей. Домены одной кампании и близкие перефразировки не должны пересекать выборки. Зафиксировать seed, идентификаторы и хеш манифеста; пороги выбрать только на validation. Если есть даты, дополнительно оценить более поздний временной срез.

B0: фиксированные правила текста и URL.
B1: символьный/словесный TF-IDF и логистическая регрессия.
B2: многоязычная модель и URL-сигналы. Обучать только после B0/B1; сравнить text-only, URL-only и combined на одном тестовом наборе.

10 Метрики и условия испытаний

Проверка	Метрика и процедура	Предварительный критерий
Детекция	Precision, recall, F1 класса fraud; macro-F1; confusion matrix, размеры выборок и 95% CI; отдельно RU/KZ.	Цель recall ≥ 0.85 и FPR ≤ 0.10 для каждого языка. Пороги согласовать; результат ещё не измерен.
Неопределённость	Доля ответов suspicious и coverage; FPR/recall считать на всех бинарных решениях, указать выбранный порог.	Не скрывать сложные случаи исключением из отчёта; abstention считать отдельно.
Задержка	p50/p95/p99, доля ошибок; 1000 запросов, 10 клиентов, локальный анализ, фиксированные CPU/RAM и версии.	NFR1: p95 ≤ 2 с; тайм-аут ≤ 5 с.
Приватность и API	Изоляция истории, удаление, отсутствие сырого текста в логах; попытки внедрения HTML и инструкций.	Обязательные проверки T1-T4 проходят; ссылки не открываются анализатором.
Пользовательский сценарий	5 добровольцев; успешность без подсказки, время задания, понимание предупреждения.	4/5 выполняют проверку; отобразить все ошибки и ограничения малой выборки.
Сравнение	B0/B1/B2, одинаковый test split; paired bootstrap для разницы F1, описать конфигурации.	Зафиксировать реальный выигрыш или его отсутствие; не переносить цифры из чужих работ.

Отчётность испытаний

Сохранять конфигурацию, версии данных и модели, команды запуска, результаты и ограничения. До запуска никаких чисел точности в отчёте не заявляется. Если 600 примеров недостаточно для устойчивого вывода, представить доверительные интервалы и план расширения корпуса.

11 Управление проектом и роли

Участник	Планируемая зона ответственности	Подтверждённый вклад на текущем этапе
Кендебаев Нұрасыл Ауесбекұлы, SE-2428	Клиент, API, PostgreSQL, сбор первичных данных, интеграция.	Создана начальная версия репозитория и рабочая документация с помощью ИИ. Проверка участником и командное review ожидаются.
Амирханов Асхат Нурланулы, SE-2428	Классификация текста, URL и домены, эксперименты и метрики.	В переданном обосновании указана роль. История коммитов и фактически выполненные задачи ещё не проверены.

Репозиторий: https://github.com/Kendebaev/FraudShield
YouTrack: https://frauddetect.youtrack.cloud/issues/DIP
Аккаунты: Kendebaev и askmirkhanov-boop.

Порядок работы

Один репозиторий на весь диплом. Для каждой значимой задачи: ответственный, ожидаемый результат, критерий приёмки и срок. ID задачи включается в ветку и описание коммита/PR; задача ссылается обратно на результат. Каждый участник работает под собственным аккаунтом. Main содержит проверенную версию; изменения проходят review второго участника.

Документация и дизайн также фиксируются по мере выполнения. Нельзя подменять реальную историю серией искусственно датированных коммитов или заявлять подготовленные автоматически материалы как уже проверенный личный вклад. Каждый участник должен проверить и объяснить свой раздел.

Контрольные точки

21 октября: репозиторий, доска и scope.
22 октября: пользовательские обсуждения, обзор и архитектура.
23 октября: отзыв руководителя, исправления, проверка доступов.
24 октября: финальный экспорт, тег prob-period-1, PDF доски, форма до 18:00. Рекомендуемое внутреннее время готовности - 16:00 по местному времени проекта.

График после 24 октября предварительный и не заменяет университетские сроки. В YouTrack созданы 15 задач с критериями; снимок списка находится в management/tasks.csv. Подготовленные разделы направлены на ревью, настройка доступов и сборка сдачи находятся в работе. Проверка командой не считается завершённой. Задачи Амирханова пока не назначены отдельному пользователю YouTrack; ответственный указан в описании.

11 Риски и готовность к сдаче

Риск	Ответственный	Снижение и сигнал пересмотра
Недостаток реальных KZ-данных	Амирханов А.Н.	Ранний пилот; отдельно RU/KZ. При нехватке данных ограничить выводы и расширить сбор.
Утечка шаблонов между split	Амирханов А.Н.	Дедупликация и группы кампаний/доменов; ручная проверка схожих сообщений.
Ложное ощущение безопасности	Оба участника	Осторожные формулировки, отдельное состояние ошибки, измерение пропусков мошенничества.
Передача личного текста	Кендебаев Н.А.	Без сохранения по умолчанию; отдельное согласие; не отправлять текст внешнему анализатору автоматически.
Сложность двух серверных стеков	Кендебаев Н.А.	Контракт и smoke-test интеграции; при задержках объединить API в одном стеке.
Недоступные ссылки при сдаче	Кендебаев Н.А.	Проверка под учётной записью проверяющего; подтверждение доступов до отправки.

Что ещё нужно подтвердить

1. Персональный доступ второго участника в репозиторий и YouTrack.
2. Реальные протоколы 3-5 бесед или содержательная договорённость с заказчиком.
3. Содержательный отзыв руководителя и выполненные по нему изменения.
4. История вклада обоих участников и review.
5. Актуальный PDF доски на дату окончательной сдачи.
6. Доступ руководителя и комиссии, совпадение отчёта с тегом сдачи.

Подписные обоснования допуска не заменяют содержательный отзыв по требованиям, архитектуре и плану оценки. Поля подписи и даты в переданных PDF пусты; наличие подписи или согласования не предполагается.

12 Материалы для предзащиты

Короткое представление проекта

Мы разрабатываем приложение для проверки подозрительных сообщений на русском и казахском языках. Пользователь вставляет текст и получает уровень риска, признаки и рекомендации. В проекте сравниваются правила, простой текстовый классификатор и многоязычный подход с URL-сигналами. Кендебаев отвечает за клиент, API и данные, Амирханов - за анализ и оценку. Качество будет измерено на обезличенном локальном корпусе с независимым тестовым разделением.

Вопросы комиссии и основа ответа

Вопрос	На что опираться в ответе
Кому и зачем нужен проект?	Проблема [10] плюс фактические беседы, когда они будут проведены. Не выдавать гипотезы за результаты.
Чем отличается от Scamio и Genie?	Собственная инженерная реализация и проверяемая локальная оценка; преимущество пока не доказано.
Почему выбран этот стек?	Раздел 5, требования и цена интеграции. Решение можно упростить по результатам прототипа.
Что означает «подозрительно»?	Зона неопределённости и набор признаков; не гарантированный диагноз и не третья истинная метка без протокола.
Как докажете качество?	B0/B1/B2, групповой test split, RU/KZ метрики, FPR, recall, CI и задержка.
Что сделал каждый?	Показать свои задачи, изменения и review; уметь объяснить каждое решение.
Что уже работает?	Показывать только реально запускаемый код. Эти материалы описывают анализ и дизайн, не готовое приложение.

На демонстрации открыть README, диаграммы, макеты, выбранную задачу и связанное изменение, затем показать замечания review. Представитель команды заполняет одну форму на всех. Отдельные PDF: общий отчёт и реальные снимки доски/задач.

Список источников

[1] Cejas O. A., Guo Y., Tang Q. (2026). **Large-Scale Multilingual SMS Fraud Detection For Telecom Networks**. NLPAICS, научная публикация.
https://aclanthology.org/2026.nlpaics-1.7/

[2] Ali F. D. M. A. et al. (2025). **MOZ-Smishing: A Benchmark Dataset for Detecting Mobile Money Frauds**. AfricaNLP, научная публикация.
https://aclanthology.org/2025.africanlp-1.23/

[3] Timko D., Rahman M. L. (2024). **Smishing Dataset I: Phishing SMS Dataset from Smishtank.com**. CODASPY, научная публикация; авторская версия arXiv.
https://arxiv.org/abs/2402.18430

[4] Nahapetyan A. et al. (2024). **On SMS Phishing Tactics and Infrastructure**. IEEE S&P, научная публикация; материалы авторов.
https://github.com/wspr-ncsu/sms-phishing

[5] Hosseinpour S., Das S. (2025). **POSTER: A Multi-Signal Model for Detecting Evasive Smishing**. WiSec, научный постер; авторская версия arXiv.
https://arxiv.org/abs/2505.18233

[6] Islam M. R. et al. (2024). **PhishGuard: A Convolutional Neural Network Based Model for Detecting Phishing URLs with Explainability Analysis**. Научный препринт arXiv.
https://arxiv.org/abs/2404.17960

[7] Togmanov M. et al. (2025). **KazMMLU: Evaluating Language Models on Kazakh, Russian, and Regional Knowledge of Kazakhstan**. ACL, научная публикация.
https://aclanthology.org/2025.acl-long.701/

[8] Conneau A. et al. (2020). **Unsupervised Cross-lingual Representation Learning at Scale**. ACL, фундаментальная научная публикация.
https://aclanthology.org/2020.acl-main.747/

[9] UCI Machine Learning Repository (2012). **SMS Spam Collection**. Датасет.
https://archive.ics.uci.edu/dataset/228/sms+spam+collection

[10] Государственный портал Республики Казахстан (2026). **Закон и порядок и защита цифровых прав граждан**. Официальные сведения о мошенничестве.
https://www.gov.kz/org/aqmola-selinograd/press/news/details/1308837?lang=ru

Дата обращения к электронным источникам: 20 октября 2026 года. Восемь научных работ [1-8], остальные - данные, официальные сведения и документация. Статус препринта указан явно.

Список источников продолжение

[11] Bitdefender (б. г.). **Scamio**. Официальное описание продукта.
https://www.bitdefender.com/en-sg/consumer/scamio

[12] Norton (б. г.). **FAQ: Norton Genie**. Официальная поддержка продукта.
https://support.norton.com/sp/en/us/home/current/solutions/v20230717145233467

[13] VirusTotal (б. г.). **How it works; Private Scanning**. Официальная документация.
https://docs.virustotal.com/docs/how-it-works

[14] Google (б. г.). **Safe Browsing**. Официальная документация.
https://developers.google.com/safe-browsing

[15] FastAPI (б. г.). **Features**. Официальная документация.
https://fastapi.tiangolo.com/features/

[16] Express (б. г.). **Express web framework**. Официальная документация.
https://expressjs.com/

[17] PostgreSQL (б. г.). **JSON Types**. Официальная документация.
https://www.postgresql.org/docs/current/datatype-json.html

[18] Telegram (б. г.). **Telegram Mini Apps**. Официальная документация.
https://core.telegram.org/bots/webapps

[19] scikit-learn (б. г.). **Text feature extraction**. Официальная документация.
https://scikit-learn.org/stable/modules/feature_extraction.html#text-feature-extraction

[20] Microsoft (б. г.). **ASP.NET Core APIs overview**. Официальная документация.
https://learn.microsoft.com/en-us/aspnet/core/fundamentals/apis?view=aspnetcore-10.0

Дополнительная документация о приватном сканировании VirusTotal: https://docs.virustotal.com/docs/private-scanning. Сравнительная таблица фиксирует только подтверждённые свойства; цены и локальное качество не предполагаются.